

UNIVERSIDAD ADOLFO IBAÑEZ

TESIS DE MAGÍSTER

Preferencias en la planificación de rutas

Autor:
Felipe Jesús Meneses
Machuca

Profesores guía:
Javiera Barrera
Luis Aburto
Felipe Lagos

*Tesis realizada acorde a los requerimientos para el grado de
Master of Science in Data Science*

de la

Facultad de Ingeniería y Ciencias

29 de junio de 2026

Índice general

1. Introducción	1
1.0.1. Descripción del Entorno Operacional: Simpliroute	1
2. Definición del problema u oportunidad	2
2.1. Problema	2
2.2. Análisis de las Causas Basado en la Literatura	2
2.2.1. Insuficiencia del criterio único de optimización	2
2.2.2. Conocimiento tácito y preferencias contextuales	3
2.2.3. Rigidez de los modelos estáticos ante contextos dinámicos . . .	3
2.3. Pregunta de Investigación	3
3. Estado del arte	4
3.1. Revisión Bibliográfica y Estado del Arte	4
3.1.1. Aprendizaje en Línea de Tiempos de Viaje mediante Bandidos Multibrazo Combinatorios	4
3.1.2. Enfoques Predictivos-Prescriptivos y Aprendizaje de Preferen- cias Multi-Objetivo	5
3.1.3. Búsqueda Local Restringida Basada en Penalizaciones Jerárqui- cas	5
3.1.4. Brecha de Conocimiento	5
Referencias	7

Capítulo 1

Introducción

La última milla constituye el eslabón final y más crítico de la cadena de suministro, encargada de conectar de manera directa el producto de una empresa con el consumidor privado final (Boysen, Fedtke, y Schwerdfeger, 2020). Asimismo, en el escenario contemporáneo, fuertemente impulsado por el auge del comercio electrónico y los servicios de entrega ultra-rápida, este proceso ha adquirido una relevancia estratégica debido a su alta complejidad operacional y sus elevados costos asociados. Así, diversos estudios en el ámbito de la ingeniería de transporte y la logística urbana señalan que la última milla es típicamente considerada la parte más ineficiente de la cadena, llegando a representar cerca del 53 % de los costos logísticos totales que enfrentan las organizaciones (Yadav, Dehalwar, y Sharma, 2025).

Por consiguiente, para las empresas del sector retail y de distribución es un imperativo crucial manejar eficientemente sus recursos. De manera que, la optimización nace como una herramienta fundamental para mejorar el manejo de recursos, reducir el consumo y organizar flotas de vehículos en tiempos viables, una tarea que sobrepasa las capacidades de planificación puramente manuales de un ser humano.

1.0.1. Descripción del Entorno Operacional: Simpliroute

Ahora bien, la oportunidad de esta investigación se genera y contextualiza en el entorno operativo de Simpliroute, una plataforma comercial de tecnología para la logística dedicada a ayudar a empresas ofreciendo entregas rápidas, eficientes e inteligentes.

Así, los clientes de Simpliroute, que incluyen empresas de retail, farmacias y restaurantes, utilizan la plataforma para optimizar sus operaciones de entrega en la última milla. De manera que, la plataforma permite a los usuarios ingresar datos de pedidos, ubicaciones de entrega y restricciones de tiempo, generando rutas optimizadas para los conductores.

Sin embargo, se ha realizado un análisis para verificar el seguimiento de las rutas generadas por Simpliroute. Donde, se ha notado que sus conductores ignoran las recomendaciones y deciden tomar su propia ruta por razones que no se han identificado, notandose una brecha entre la ruta óptima generada por el algoritmo y la ruta ejecutada en el mundo real.

En consecuencia, este fenómeno de no adherencia a la ruta óptima representa un desafío crítico para la eficiencia operativa de Simpliroute, ya que impacta directamente en el uso de recursos de los clientes e incluso en los costos logísticos y en la satisfacción del cliente.

Capítulo 2

Definición del problema u oportunidad

2.1. Problema

El problema central de esta investigación radica en la severa degradación de la adherencia a la secuencia de clientes planificada por la heurística de SimpliRoute. Así, en el contexto de la última milla, el software modela la operación como un Problema de Ruteo de Vehículos (VRP)[comentario:no se si el software lo modela directamente como una vrp, no se nada del software, solo se que es una heurística], donde el objetivo principal es determinar una permutación ordenada de paradas para cada vehículo, minimizando una función de costo basada en distancias y tiempos teóricos de viaje. Sin embargo, los datos empíricos de la plataforma revelan una desconexión crítica con la realidad. Ya que, la tasa de adherencia de los conductores a la secuencia exacta de clientes propuesta por Simpliroute alcanza apenas un 14.19 % (Rubio Carrasco, 2025). Asimismo, esto significa que en el 85.81 % de los casos, los operadores alteran deliberadamente el orden de visita de los nodos o clientes a visitar. De manera que, este fenómeno representa un desajuste estructural entre el espacio de soluciones del algoritmo y las decisiones secuenciales óptimas del operador humano.

La persistencia de esta baja adherencia impacta negativamente en la eficiencia proyectada por la plataforma, alterando las estimaciones de tiempos de llegada y de los costos logísticos, arriesgando la confiabilidad del servicio de SimpliRoute.

2.2. Análisis de las Causas Basado en la Literatura

La drástica desviación conductual de los operadores logísticos responde a variables críticas que la heurística tradicional omite. Este desajuste puede descomponerse en tres lógicas principales para entender el problema.

2.2.1. Insuficiencia del criterio único de optimización

Primero, Los motores de ruteo tradicionales resuelven el Problema de Ruteo de Vehículos (VRP) modelando una función de costo lineal que minimiza variables geométricas o temporales explícitas, tales como la distancia total o el tiempo teórico de viaje. Sin embargo, la evidencia empírica señala que los conductores expertos operan bajo un esquema multiobjetivo subjetivo y rara vez eligen el camino más corto o rápido de forma aislada

La literatura identifica que los operadores humanos evalúan de forma latente la calidad de la infraestructura y el estrés de la conducción. Por ejemplo, desvían sus rutas deliberadamente para evitar segmentos viales con pavimentos en mal estado, zonas con exceso de semáforos, giros complejos a la izquierda en avenidas saturadas, entre otros (Zattoni Scroccaro, van Beek, Mohajerin Esfahani, y Atasoy, 2025) (Cook, Held, y Helsgaun, 2024) (Yang, Guo, Ma, y Jensen, 2015) (Pan y cols., 2025) (Ceikute y Jensen, 2013) (Chen, Chang, y Tzeng, 2001). Al omitir estas variables en la función de costo del planificador, el espacio de soluciones del algoritmo se vuelve impracticable en la realidad.

2.2.2. Conocimiento tácito y preferencias contextuales

Segundo, la causa crítica es la exclusión del conocimiento asimétrico que posee el conductor frente a la plataforma logística. A través de la repetición sistemática de sus rutas, los repartidores desarrollan una profunda familiaridad con sus zonas asignadas, acumulando un “conocimiento tácito” (tacit knowledge) que no está digitalizado en las bases de datos del sistema (Merchán y cols., 2024) (Canoy, Bucarey, Mandi, y Guns, 2023) (Ceikute y Jensen, 2013) (Özarik, da Costa, y Florio, 2024).

Este aprendizaje basado en la experiencia les permite anticipar dinámicas locales que el algoritmo ignora de forma nativa. Entre ellas destacan la disponibilidad real de estacionamiento en zonas de alta densidad, las ventanas efectivas de recepción de los clientes (que suelen diferir de las ventanas teóricas ingresadas en la plataforma) y factores del entorno como los horarios de congestión inducida por escuelas o comercios locales (Rastogi, 2023; Ulmer y cols., 2020). Al verse enfrentado a una secuencia algorítmica que contradice esta experiencia, el conductor prioriza su propio criterio heurístico para garantizar la efectividad de la entrega (Li y Phillips, 2018).

2.2.3. Rigidez de los modelos estáticos ante contextos dinámicos

Por último, la literatura atribuye las desviaciones a la naturaleza determinista o estática con la que se suelen calcular las matrices de tiempo de viaje en los planificadores comerciales. Mientras que la plataforma calcula un plan rígido al inicio de la jornada utilizando velocidades promedio, el entorno de la última milla es altamente estocástico y sensible al contexto (Guo y cols., 2020).

Los cambios en las condiciones climáticas, la congestión vehicular imprevista o eventos disruptivos en la red vial obligan al conductor a tomar decisiones adaptativas en tiempo real basándose en información local (Tang y Levinson, 2018). Al no existir un mecanismo dinámico que permita al motor de optimización aprender cómo varían las preferencias de ruta según el contexto horario o espacial de cada conductor individual, el plan original se vuelve obsoleto a las pocas horas de iniciar la operación.

2.3. Pregunta de Investigación

En base a los antecedentes expuestos, la presente investigación busca responder a la siguiente interrogante ¿Cómo se pueden modelar e integrar las preferencias operacionales latentes de los conductores, inferidas a partir de las discrepancias entre rutas planificadas y trazas GPS históricas, para lograr una mayor adherencia del motor de optimización vehicular?

Capítulo 3

Estado del arte

3.1. Revisión Bibliográfica y Estado del Arte

Esta discrepancia entre ruta ejecutada no es exclusiva de SimpliRoute, sino que ha sido documentada de forma sistemática en la última milla bajo distintos nombres, como implicit preferences (incertar cita de canoy, bucarey mandi y guns 2023), tacit knowledge (cita merchant y cols, 2024) o context-aware preferences (GUO, yang, gy, jensen y chen 2020. Cook, held y helsgaun 2022), a partir del desafío de datos de Amazon, cuantificaron que las rutas ejecutadas por conductores reales son en promedio un 12,9 % más largas en tiempo de viaje que la solución óptima teórica, evidencia de que el conductor no minimiza linealmente el tiempo de trayecto sino que opera bajo criterios implícitos. La magnitud del fenómeno en SimpliRoute (85,81 % de desviación) sugiere que, lejos de ser una anomalía marginal, el motor de ruteo está resolviendo sistemáticamente un problema distinto al que el conductor enfrenta en terreno.

La literatura científica contemporánea en logística de última milla ha transitado desde modelos prescriptivos hacia marcos adaptativos basados en datos. Así, estos enfoques modernos buscan capturar la incertidumbre del entorno urbano, las dinámicas operacionales complejas y el conocimiento tácito humano a través de un historial de datos pasados. De manera que, para fundamentar metodológicamente esta investigación, el estado del arte se divide en tres pilares esenciales. Primero, el aprendizaje utilizando bandidos multibrazo, luego la inferencia de preferencias multi-objetivo y el modelamiento de secuencias micro a través de penalizaciones.

3.1.1. Aprendizaje en Línea de Tiempos de Viaje mediante Bandidos Multibrazo Combinatorios

Una vertiente fundamental de la literatura aborda el problema desde la perspectiva del aprendizaje adaptativo de la red de transporte en escenarios donde el operador logístico posee información limitada o estocástica sobre los tiempos reales de viaje (Lagos, Auad, y Lagos, 2024). Por lo tanto, (Lagos y cols., 2024) formalizan el Problema del camino más corto modelándolo matemáticamente como un problema de bandidos multibrazo combinatorios (CMAB) bajo un entorno de retroalimentación de tipo semibandit. Bajo este esquema, el planificador recolecta de forma directa las realizaciones puntuales de los tiempos de viaje de cada arco individual perteneciente al camino ejecutado por la flota (Lagos y cols., 2024). Asimismo, esta metodología consta de dos fases, entre exploración y explotación basado en el algoritmo de thompson sampling.

3.1.2. Enfoques Predictivos-Prescriptivos y Aprendizaje de Preferencias Multi-Objetivo

Una línea de investigación complementaria se enfoca en el aprendizaje de preferencias a nivel macro, donde (Nourmohammadi, Hu, Rey, y Saberi, 2025) introducen un enfoque de optimización guiado por datos para inferir implícitamente las ponderaciones de las funciones objetivo en un Problema de Ruteo Vehicular Capacitado con Ventanas de Tiempo Multi-Objetivo (MO-CVRPTW). A diferencia de los métodos de Optimización Inversa (IO), los cuales suelen operar sin interpretación clara.

Así, este marco utiliza la escalarización y normalización de objetivos, para resolver la (Nourmohammadi y cols., 2025)disparidad de escalas numéricas entre las distintas métricas de las funciones objetivos. Luego, tras evaluar estadísticamente un conjunto de escenarios históricos, los autores demostraron que las preferencias tomadores de decisiones logísticas se concentran en tres objetivos principales, la minimización de distancia total de viaje, la minimización del tamaño de la flota utilizada y el balance de carga de trabajo. Finalmente, utilizan el algoritmo de bosques aleatorios(RF) para predecir las funciones objetivos a partir de las características intrínsecas de las intancias de entrega, eliminando la necesidad de compilar el motor de optimización en cada exploración de pesos. (Nourmohammadi y cols., 2025). Pero, una premisa fundamental de este enfoque es asumir de la homogeneidad en las preferencias de la flota, es decir, el modelo no busca parametrizar el comportamiento aislado de cada conductor, sino capturar la visión unificada del tomador de decisiones. (Nourmohammadi y cols., 2025).

3.1.3. Búsqueda Local Restringida Basada en Penalizaciones Jerárquicas

Un hito fundamental en el modelamiento del comportamiento del conductor a nivel micro (secuenciación de paradas) fue establecido poner cita, quienes desarrollaron el algoritmo LKH-AMZ para competir en el Amazon Last Mile Routing Research Challenge de 2021 (Merchán y cols., 2024). Donde, los autores abordan el problema de la secuencia detallada de un único vehículo tratándolo formalmente como un Problema del Vendedor Viajero Asimétrico (ATSP) (? , ?). Para aproximar las soluciones teóricas a las decisiones reales, los autores propusieron un enfoque basado en la optimización local restringida por penalizaciones (? , ?).

El algoritmo LKH-AMZ obtuvo el primer lugar global de la competencia al alcanzar un score de 0.0248 frente a los datos ocultos de Amazon, demostrando alta eficiencia computacional al procesar instancias complejas en fracciones de segundo (? , ?).

3.1.4. Brecha de Conocimiento

A partir de la revisión sistemática de la literatura se constatan tres limitaciones críticas en los enfoques actuales para resolver la baja adherencia en la última milla:

Por un lado, la metodología de (? , ?) modela el conocimiento tácito penalizando las secuencias según la estructuración geográfica intrínseca de los datos de Amazon. Sin embargo, este enfoque posee una dependencia absoluta del atributo de zonas, imposibilitando su aplicación en contextos comerciales locales (como Simpliroute) donde las bodegas y manifiestos de carga no cuentan con zonificaciones preestablecidas de fábrica.

Por otra parte, los marcos avanzados de aprendizaje en línea para transporte, tales como los Bandidos Multibrazo Combinatorios (CMAB), han demostrado alta eficiencia para aprender dinámicas de tráfico en redes urbanas bajo incertidumbre (Lagos y cols., 2024). Pero, su aplicación directa a la última milla es compleja, ya que estos modelos están diseñados para la optimización de un único par origen-destino (OSPP) en entornos de exploración activa, siendo incapaces de incorporar restricciones complejas de secuenciación de múltiples paradas (VRP) y ventanas de tiempo, ni de explotar de forma pasiva el conocimiento histórico de trazas GPS preexistentes de la flota.

Finalmente, los enfoques híbridos predictivos-prescriptivos orientados al aprendizaje de preferencias multi-objetivo en plataformas, como el de (Nourmohammadi y cols., 2025), logran inferir pesos globales del sistema bajo supuestos de homogeneidad en la flota (Nourmohammadi y cols., 2025).

Por tanto, existe la necesidad evidente de formular un marco que adapte los principios de aprendizaje secuencial y estocástico, como las características de los bandidos combinatorio, para operar sobre decisiones secuenciales discretas (VRP), utilizando de forma pasiva las trazas GPS históricas para inferir las preferencias y agrupaciones latentes de la flota, identificando si es necesario o no prescindir o no de metadatos de zonificación.

Referencias

- Boysen, N., Fedtke, S., y Schwerdfeger, S. (2020). Last-mile delivery concepts: a survey from an operational research perspective. *Or Spectrum*, 43(1), 1–58.
- Canoy, R., Bucarey, V., Mandi, J., y Guns, T. (2023). Learn and route: learning implicit preferences for vehicle routing. *Constraints*, 28(3), 363–396.
- Ceikute, V., y Jensen, C. S. (2013). Routing service quality – local driver behavior versus routing services. En *2013 IEEE 14th international conference on mobile data management* (Vol. 1, p. 97-106). doi: 10.1109/MDM.2013.20
- Chen, T.-Y., Chang, H.-L., y Tzeng, G.-H. (2001). Using a weight-assessing model to identify route choice criteria and information effects. *Transportation Research Part A: Policy and Practice*, 35(3), 197–224.
- Cook, W., Held, S., y Helsgaun, K. (2024). Constrained local search for last-mile routing. *Transportation Science*, 58(1), 12–26.
- Lagos, T., Auad, R., y Lagos, F. (2024). The online shortest path problem: Learning travel times using a multiarmed bandit framework. *Transportation Science*, 1–32. (Articles in Advance) doi: 10.1287/trsc.2023.0196
- Merchán, D., Arora, J., Pachon, J., Konduri, K., Winkenbach, M., Parks, S., y Noszek, J. (2024). 2021 amazon last mile routing research challenge: Data set. *Transportation Science*, 58(1), 8–11.
- Nourmohammadi, Z., Hu, B., Rey, D., y Saberi, M. (2025). A data-driven preference learning approach for multi-objective vehicle routing problems in last-mile delivery. *Transportation Research Part C*, 174, 105101. doi: 10.1016/j.trc.2025.105101
- Özarık, S. S., da Costa, P., y Florio, A. M. (2024). Machine learning for data-driven last-mile delivery optimization. *Transportation Science*, 58(1), 27–44.
- Pan, B., Wu, Y., Cao, Z., Hou, Y., Zou, G., y Zhang, Q. (2025). Preference-based deep reinforcement learning for historical route estimation.
- Rubio Carrasco, T. (2025). *Mejora de adherencia a planificación de ruteo usando machine learning basado en preferencias pasadas* (Tesis de magíster). Universidad Adolfo Ibáñez, Santiago, Chile.
- Yadav, K., Dehalwar, K., y Sharma, S. N. (2025). Assessing the factors affecting first and last mile accessibility in transit-oriented development: A literature review. *GeoJournal*, 90(6), 298.
- Yang, B., Guo, C., Ma, Y., y Jensen, C. S. (2015). Toward personalized, context-aware routing. *The VLDB Journal*, 24(2), 297–318.
- Zattoni Scroccaro, P., van Beek, P., Mohajerin Esfahani, P., y Atasoy, B. (2025). Inverse optimization for routing problems. *Transportation Science*, 59(2), 301–321.