

UNIVERSIDAD ADOLFO IBAÑEZ

TESIS DE MAGÍSTER

Preferencias en la planificación de rutas

Autor:
Felipe Jesús Meneses
Machuca

Profesores guía:
Javiera Barrera
Luis Aburto
Felipe Lagos

*Tesis realizada acorde a los requerimientos para el grado de
Master of Science in Data Science*

de la

Facultad de Ingeniería y Ciencias

29 de junio de 2026

Índice general

1. Introducción	1
1.1. Descripción del Entorno Operacional: Simpliroute	1
2. Definición del problema u oportunidad	2
2.1. Problema	2
2.2. Análisis de las Causas Basado en la Literatura	2
2.3. Pregunta de Investigación	3
3. Estado del arte	4
3.1. Revisión Bibliográfica y Estado del Arte	4
3.2. Literatura	4
3.2.1. Aprendizaje de Preferencias Implícitas mediante Modelos Probabilísticos de Transición	4
3.2.2. Optimización Inversa Aplicada al Ruteo de Vehículos	5
3.2.3. Aprendizaje por Refuerzo Inverso y Aprendizaje Profundo Basado en Preferencias con Trazas GPS	6
3.3. Brecha de Conocimiento	7
Referencias	8

Capítulo 1

Introducción

La última milla constituye el eslabón final y más crítico de la cadena de suministro, encargada de conectar de manera directa el producto de una empresa con el consumidor privado final (Boysen, Fedtke, y Schwerdfeger, 2020). Asimismo, en el escenario contemporáneo, fuertemente impulsado por el auge del comercio electrónico y los servicios de entrega ultra-rápida, este proceso ha adquirido una relevancia estratégica debido a su alta complejidad operacional y sus elevados costos asociados. Así, diversos estudios en el ámbito de la ingeniería de transporte y la logística urbana señalan que la última milla es típicamente considerada la parte más ineficiente de la cadena, llegando a representar cerca del 53 % de los costos logísticos totales que enfrentan las organizaciones (Yadav, Dehalwar, y Sharma, 2025).

Por consiguiente, para las empresas del sector retail y de distribución es un imperativo crucial manejar eficientemente sus recursos. De manera que, la optimización nace como una herramienta fundamental para mejorar el manejo de recursos, reducir el consumo y organizar flotas de vehículos en tiempos viables, una tarea que sobrepasa las capacidades de planificación puramente manuales de un ser humano.

1.1. Descripción del Entorno Operacional: Simpliroute

Ahora bien, la oportunidad de esta investigación se genera y contextualiza en el entorno operativo de Simpliroute, una plataforma comercial de tecnología para la logística dedicada a ayudar a empresas ofreciendo entregas rápidas, eficientes e inteligentes.

Así, los clientes de Simpliroute, que incluyen empresas de retail, farmacias y restaurantes, utilizan la plataforma para optimizar sus operaciones de entrega en la última milla. De manera que, la plataforma permite a los usuarios ingresar datos de pedidos, ubicaciones de entrega y restricciones de tiempo, generando rutas optimizadas para los conductores.

Sin embargo, se ha realizado un análisis para verificar el seguimiento de las rutas generadas por Simpliroute. Donde, se ha notado que sus conductores ignoran las recomendaciones y deciden tomar su propia ruta por razones que no se han identificado, notandose una brecha entre la ruta óptima generada por el algoritmo y la ruta ejecutada en el mundo real.

En consecuencia, este fenómeno de no adherencia a la ruta óptima representa un desafío crítico para la eficiencia operativa de Simpliroute, ya que impacta directamente en el uso de recursos de los clientes e incluso en los costos logísticos y en la satisfacción del cliente.

Capítulo 2

Definición del problema u oportunidad

2.1. Problema

El problema central de esta investigación radica en la severa degradación de la adherencia a la secuencia de clientes planificada por la heurística de SimpliRoute. Así, en el contexto de la última milla, el software modela la operación como un Problema de Ruteo de Vehículos (VRP)[comentario:no se si el software lo modela directamente como una vrp, no se nada del software, solo se que es una heurística], donde el objetivo principal es determinar una permutación ordenada de paradas para cada vehículo, minimizando una función de costo basada en distancias y tiempos teóricos de viaje. Sin embargo, los datos empíricos de la plataforma revelan una desconexión crítica con la realidad. Ya que, la tasa de adherencia de los conductores a la secuencia exacta de clientes propuesta por Simpliroute alcanza apenas un 14.19 % (Rubio Carrasco, 2025). Asimismo, esto significa que en el 85.81 % de los casos, los operadores alteran deliberadamente el orden de visita de los nodos o clientes a visitar. De manera que, este fenómeno representa un desajuste estructural entre el espacio de soluciones del algoritmo y las decisiones secuenciales óptimas del operador humano.

La persistencia de esta baja adherencia impacta negativamente en la eficiencia proyectada por la plataforma, alterando las estimaciones de tiempos de llegada y de los costos logísticos, arriesgando la confiabilidad del servicio de SimpliRoute.

2.2. Análisis de las Causas Basado en la Literatura

La drástica brecha de adherencia observada no responde a una indisciplina arbitraria del operador logístico, sino a un divorcio estructural entre la formulación matemática del optimizador y la realidad operativa en terreno.

En primer lugar, los motores de ruteo tradicionales resuelven el Problema de Ruteo de Vehículos (VRP) mediante una función de costo lineal que minimiza variables geométricas o temporales explícitas, tales como la distancia total o el tiempo teórico de viaje. Sin embargo, la evidencia empírica señala que los conductores expertos operan bajo un esquema multiobjetivo subjetivo y rara vez eligen el camino más corto o rápido de forma aislada.

La literatura identifica que los operadores humanos evalúan de forma latente variables complejas como la calidad de la infraestructura y el estrés de la conducción; por ejemplo, desvían sus rutas deliberadamente para evitar segmentos viales con

pavimentos en mal estado, zonas con exceso de semáforos o giros complejos a la izquierda en avenidas saturadas (Zattoni Scroccaro, van Beek, Mohajerin Esfahani, y Atasoy, 2025; Cook, Held, y Helsgaun, 2024; Yang, Guo, Ma, y Jensen, 2015; Pan y cols., 2025; Ceikute y Jensen, 2013; Chen, Chang, y Tzeng, 2001). Al omitir estos factores en la función de costo del planificador, el espacio de soluciones del algoritmo se vuelve impracticable en la realidad.

Esta desconexión basada en la simplificación del modelo se profundiza críticamente debido a la exclusión del conocimiento asimétrico que posee el conductor frente a la plataforma. A través de la repetición sistemática de sus rutas, los repartidores desarrollan una profunda familiaridad con sus zonas asignadas, acumulando un conocimiento tácito que no es considerado (Merchán y cols., 2024; Canoy, Bucarey, Mandi, y Guns, 2023; Ceikute y Jensen, 2013; Özarık, da Costa, y Florio, 2024). Este aprendizaje basado en la experiencia les permite anticipar e integrar de forma intuitiva dinámicas locales variables que el algoritmo ignora de forma nativa, tales como la disponibilidad real de estacionamiento en zonas de alta densidad, las ventanas efectivas de recepción de los clientes (que suelen diferir de las ventanas teóricas ingresadas en el sistema) y factores del entorno como la congestión intermitente inducida por escuelas o comercios locales.

En consecuencia, al verse enfrentado a una secuencia algorítmica rígida que contradice este entendimiento empírico del entorno, el conductor opta por priorizar su propio criterio heurístico para asegurar la efectividad real de la entrega, consolidando el fenómeno de desviación analizado.

2.3. Pregunta de Investigación

En base a los antecedentes expuestos, la presente investigación busca responder a la siguiente interrogante ¿Cómo se pueden inferir e integrar las preferencias multiobjetivo y el conocimiento tácito de los conductores, a partir de las discrepancias entre rutas planificadas y trazas GPS históricas, para incrementar la adherencia a la secuencia de paradas por visitar, del motor de optimización en la última milla?

Capítulo 3

Estado del arte

3.1. Revisión Bibliográfica y Estado del Arte

Esta discrepancia entre ruta ejecutada no es exclusiva de SimpliRoute, sino que ha sido documentada de forma sistemática en la última milla bajo distintos nombres, como implicit preferences (Canoy y cols., 2023), tacit knowledge (Merchán y cols., 2024) o context-aware preferences (Cook y cols., 2024), a partir del desafío de datos de Amazon, cuantificaron que las rutas ejecutadas por conductores reales son en promedio un 12,9 % más largas en tiempo de viaje que la solución óptima teórica, evidencia de que el conductor no minimiza linealmente el tiempo de trayecto sino que opera bajo criterios implícitos. La magnitud del fenómeno en SimpliRoute (85,81 % de desviación) sugiere que, lejos de ser una anomalía marginal, el motor de ruteo está resolviendo sistemáticamente un problema distinto al que el conductor enfrenta en terreno.

La literatura científica contemporánea en logística de última milla ha transitado desde modelos prescriptivos hacia marcos adaptativos basados en datos. Así, estos enfoques modernos buscan capturar la incertidumbre del entorno urbano, las dinámicas operacionales complejas y el conocimiento tácito humano a través de un historial de datos pasados. De manera que, para fundamentar metodológicamente esta investigación, el estado del arte se divide en tres pilares esenciales. Primero, el aprendizaje

3.2. Literatura

Ahora bien, para resolver este problema en el contexto de Simpliroute se requiere considerar tres aspectos clave. Primero, heterogeneidad individual, es decir, la diferencia en el comportamiento de los conductores frente a la misma trayectoria no es la misma, donde idealmente se pueda aprender el perfil único de cada conductor, no un promedio de la zona. Segundo, lograr una escalabilidad, debe funcionar con una gran cantidad de carteras de clientes que cambian todos los días y trazas GPS dispersas. Y, por último, reinyectabilidad operacional, donde el resultado sea directamente consumible por el motor de optimización de Simpliroute.

3.2.1. Aprendizaje de Preferencias Implícitas mediante Modelos Probabilísticos de Transición

En la práctica logística, un planificador experimentado rara vez acepta sin modificaciones la ruta que propone un software de optimización: la ajusta según su conocimiento del terreno, la historia de cada cliente y las restricciones tácitas que ha aprendido con el tiempo. Un sistema que pueda aprender esas modificaciones de

forma automática, sin que el planificador deba articular explícitamente sus razones, representaría una mejora significativa para la adherencia operacional.

Con ese objetivo, Canoy, Bucarey, Mandi y Guns (2023) proponen un marco de aprendizaje de preferencias implícitas para el VRP basado en un modelo de transición markoviano entre paradas. La idea central consiste en reemplazar la matriz de distancias del solver VRP por una *matriz de probabilidades de transición* estimada a partir de las rutas manuales históricas: cuanto más frecuentemente un planificador haya encadenado la parada AA A con la parada BB B en el pasado, mayor será la probabilidad de transición de AA A hacia BB B en el modelo. Esta matriz aprendida se integra directamente con la infraestructura de optimización existente, combinando el criterio objetivo de distancia con el criterio subjetivo de preferencia, sin necesidad de reformular matemáticamente el VRP subyacente. En su validación sobre datos reales de una empresa de transporte, los autores demuestran que las rutas generadas con la matriz aprendida se acercan sistemáticamente más a las soluciones manuales del planificador que las rutas puramente basadas en distancias, incluso ante cambios en el conjunto de clientes.

No obstante, este enfoque presenta una limitación fundamental en el contexto de SimpliRoute. El modelo captura la co-ocurrencia histórica entre arcos, pero no la causa subyacente de cada preferencia. Si dos conductores distintos han encadenado con frecuencia las mismas paradas por razones completamente diferentes —uno por familiaridad con el sector, otro por una restricción horaria implícita de un cliente— el modelo agrega ambos patrones sin distinguirlos. Esta mezcla de motivos heterogéneos deteriora la calidad de la predicción cuando distintos conductores operan sobre la misma cartera de clientes, situación habitual en la operación diaria de SimpliRoute.

3.2.2. Optimización Inversa Aplicada al Ruteo de Vehículos

Cuando un conductor experto elige una ruta, implícitamente está resolviendo un problema de optimización cuya función objetivo no está siendo modelada matemáticamente. La Optimización Inversa (IO) invierte esta lógica, es decir, en lugar de resolver un problema de optimización dado un objetivo conocido, infiere el objetivo a partir de las soluciones observadas (Ahuja y Orlin, 2001). De manera que, aplicada al ruteo, permite estimar qué pesos latentes sobre distintos atributos viales y operacionales habrían producido las rutas ejecutadas históricamente por un conductor.

Ahora bien, esta metodología ha sido formalizada para el VRP (Zattoni Scroccaro y cols., 2025), proponiendo una metodología de IO con función hipótesis, función de pérdida y algoritmo de optimización estocástico de primer orden adaptados a las restricciones estructurales del problema de ruteo. El marco parte del supuesto de que las rutas históricas ejecutadas por los conductores son soluciones aproximadamente óptimas de un VRP cuya función de costo verdadera es desconocida. Así, a través de IO, se estima el vector de pesos latente que refleja las preferencias implícitas del decisor. En su validación sobre el desafío de última milla de Amazon (2021), los autores aprenden las preferencias de los conductores en términos de zonas geográficas predefinidas de la ciudad, alcanzando el segundo lugar entre los 48 equipos finalistas con un puntaje de 0.0302.

Sin embargo, existen dos limitaciones relevantes frente al contexto de SimpliRoute. Primero, la implementación principal del marco depende de la existencia de una zonificación geográfica preestablecida. Ya que, en SimpliRoute, las bodegas de los

clientes y los manifiestos de carga no cuentan con una estructura de zonas previamente definida, equivalente a la de Amazon, lo que impide la transferencia directa del enfoque. Segundo, la IO aprende un único vector de parámetros para el conjunto de todas las rutas analizadas, representando un promedio de la flota más que el perfil individual de cada conductor. Por lo tanto, tanto la dependencia de la zonificación, como la homogeneización de la flota, constituyen brechas directas respecto de los requisitos del problema bajo estudio.

3.2.3. Aprendizaje por Refuerzo Inverso y Aprendizaje Profundo Basado en Preferencias con Trazas GPS

El Aprendizaje por Refuerzo Inverso (IRL) parte de una premisa intuitiva, si se observa el comportamiento de un agente que toma decisiones de forma experta, es posible inferir la función de recompensa que dicho agente está maximizando, aunque esa función nunca haya sido formulada explícitamente (Ng, Russell, y cols., 2000).

En el dominio del ruteo vehicular, esto significa que a partir de un historial de trazas GPS es posible aprender qué combinación latente de factores viales está pesando el conductor al elegir sus rutas, sin que él deba declararlo.

Sin embargo, aun presenta ciertas complicaciones, donde identifican dos limitaciones técnicas que afectan a los métodos IRL estándar cuando se aplican sobre trazas GPS reales en redes viales urbanas (Zhang, Lei, Liu, y Jiang, 2024). Por un lado, estimar las frecuencias esperadas de visita a cada segmento vial, requiere aproximaciones numéricas iterativas que son simultáneamente costosas en cómputo e imprecisas. Por otro lado, la cobertura de las trazas GPS está sesgada hacia los tramos más transitados, dificultando el aprendizaje de preferencias en segmentos poco frecuentados.

Así, para superar ambas limitaciones, los autores proponen combinar el modelo de logit recursivo, que deriva analíticamente las frecuencias esperadas, reduciendo el tiempo de cómputo en más de un 95 %, el cual transfiere el conocimiento adquirido en tramos populares hacia tramos escasamente cubiertos. De manera que, la validación sobre datos GPS reales de la ciudad de Chengdu muestra que las rutas planificadas con este enfoque presentan mayor correspondencia con las trayectorias ejecutadas que los métodos de IRL de referencia.

Por su parte, (Pan y cols., 2025) proponen un enfoque de Aprendizaje por Refuerzo Profundo Basado en Preferencias (PbRL), cuya función de recompensa está especializada para aprender de comparaciones entre rutas históricas completas. Así, el modelo utiliza una red neuronal entrenada sobre el Problema de Ruteo Vehicular Capacitado (CVRP). Donde, demuestra que incorporar señales de preferencia humana permite generar soluciones más alineadas con el comportamiento histórico de los conductores que los métodos de aprendizaje para optimización, los cuales se limitan a minimizar distancia o tiempo de viaje.

No obstante, ambos enfoques presentan limitaciones críticas frente al problema de SimpliRoute. El método de (Zhang y cols., 2024) fue concebido y validado para ruteo de un único par origen-destino en redes urbanas (conducción diaria y *ride-hailing*), un contexto donde la decisión consiste en elegir un camino entre dos puntos fijos sobre un grafo vial. Pero, el problema de SimpliRoute tiene una estructura combinatoria distinta: no se trata de elegir un camino, sino de determinar la secuencia óptima

entre múltiples paradas (VRP), un espacio de decisión exponencialmente mayor para el cual estos modelos no han sido adaptados. En cuanto al enfoque de (Pan y cols., 2025), la función de recompensa aprendida compara rutas completas entre sí sin descomponerla en los factores viales individuales que la gobiernan, lo que limita la reinyectabilidad del modelo directamente en la heurística de Simpliroute.

3.3. Brecha de Conocimiento

A partir de la revisión de las cinco familias metodológicas presentadas, se constatan tres limitaciones estructurales que ninguna de ellas resuelve de forma simultánea frente al problema específico de SimpliRoute.

Primera limitación: heterogeneidad individual no modelada. Los métodos de aprendizaje de preferencias multiobjetivo a nivel de plataforma (Nourmohammadi y cols., 2025) y la IO aplicada a ruteo (Zattoni Scroccaro y cols., 2025) estiman un conjunto único de parámetros para toda la flota, asumiendo homogeneidad entre conductores. Sin embargo, el análisis exploratorio desarrollado en esta tesis evidencia que distintos operadores que cubren una misma zona de reparto exhiben patrones de secuenciación sistemáticamente diferentes: la variación en el uso de tipos de vía no es aleatoria sino consistente por conductor. Un modelo que promedia la flota introduce ruido y oculta los perfiles individuales que determinan la adherencia real.

Segunda limitación: imposibilidad de separar el efecto de zona del efecto de preferencia personal. Los métodos jerárquicos basados en zonificación (Cook y cols., 2024) y la IO con zonas preestablecidas (Zattoni Scroccaro y cols., 2025) descansan en una estructura geográfica predefinida que no existe en SimpliRoute. Más relevante aún, el análisis exploratorio de esta tesis identifica que parte de la variación observada en el comportamiento de los conductores es atribuible a la asignación de zona —un efecto estructural y colectivo— y no exclusivamente a la preferencia personal. Ninguno de los métodos revisados ofrece un mecanismo para disociar ambos efectos, lo cual puede llevar a atribuir patrones geográficos de la zona a preferencias personales del conductor, o viceversa.

Tercera limitación: ausencia de reinyectabilidad operacional en el motor VRP. Los enfoques de IRL y PbRL (Zhang y cols., 2024; Pan y cols., 2025) aprenden una representación de la preferencia del conductor a partir de trazas GPS, pero dicha representación no está formulada como una corrección directamente aplicable a la función de costo de un solver VRP existente. En el contexto operativo de SimpliRoute, el resultado metodológico debe ser consumible por el motor de optimización —ya sea como un vector de pesos ajustado en la función de costo o como una restricción blanda aprendida— sin requerir el rediseño completo del sistema de ruteo.

En síntesis, existe una brecha metodológica no cubierta en la intersección de estas tres condiciones: un marco capaz de inferir preferencias latentes **a nivel individual por conductor, distinguiendo el efecto estructural de la asignación de zona del efecto personal**, y cuyo resultado sea **directamente reinyectable en un motor de optimización VRP**. Esta investigación se posiciona en esa intersección, aprovechando además la disponibilidad infrecuente en la literatura de trazas GPS de alta frecuencia con contrapartes de rutas planificadas por conductor —un tipo de dato señalado repetidamente como la principal barrera para avanzar en esta línea (Merchán y cols., 2024; Cook y cols., 2024).

Referencias

- Ahuja, R. K., y Orlin, J. B. (2001). Inverse optimization. *Operations research*, 49(5), 771–783.
- Boysen, N., Fedtke, S., y Schwerdfeger, S. (2020). Last-mile delivery concepts: a survey from an operational research perspective. *Or Spectrum*, 43(1), 1–58.
- Canoy, R., Bucarey, V., Mandi, J., y Guns, T. (2023). Learn and route: learning implicit preferences for vehicle routing. *Constraints*, 28(3), 363–396.
- Ceikute, V., y Jensen, C. S. (2013). Routing service quality – local driver behavior versus routing services. En *2013 IEEE 14th international conference on mobile data management* (Vol. 1, p. 97-106). doi: 10.1109/MDM.2013.20
- Chen, T.-Y., Chang, H.-L., y Tzeng, G.-H. (2001). Using a weight-assessing model to identify route choice criteria and information effects. *Transportation Research Part A: Policy and Practice*, 35(3), 197–224.
- Cook, W., Held, S., y Helsgaun, K. (2024). Constrained local search for last-mile routing. *Transportation Science*, 58(1), 12–26.
- Merchán, D., Arora, J., Pachon, J., Konduri, K., Winkenbach, M., Parks, S., y Noszek, J. (2024). 2021 amazon last mile routing research challenge: Data set. *Transportation Science*, 58(1), 8–11.
- Ng, A. Y., Russell, S., y cols. (2000). Algorithms for inverse reinforcement learning. En *Icml* (Vol. 1, p. 2).
- Özarık, S. S., da Costa, P., y Florio, A. M. (2024). Machine learning for data-driven last-mile delivery optimization. *Transportation Science*, 58(1), 27–44.
- Pan, B., Wu, Y., Cao, Z., Hou, Y., Zou, G., y Zhang, Q. (2025, August). Preference-based deep reinforcement learning for historical route estimation. En *Proceedings of the thirty-fourth international joint conference on artificial intelligence (ijcai 2025)*. Montreal, Canada: International Joint Conferences on Artificial Intelligence Organization. Descargado de <https://doi.org> doi: 10.24963/ijcai.2025/955
- Rubio Carrasco, T. (2025). *Mejora de adherencia a planificación de ruteo usando machine learning basado en preferencias pasadas* (Tesis de magíster). Universidad Adolfo Ibáñez, Santiago, Chile.
- Yadav, K., Dehalwar, K., y Sharma, S. N. (2025). Assessing the factors affecting first and last mile accessibility in transit-oriented development: A literature review. *GeoJournal*, 90(6), 298.
- Yang, B., Guo, C., Ma, Y., y Jensen, C. S. (2015). Toward personalized, context-aware routing. *The VLDB Journal*, 24(2), 297–318.
- Zattoni Scroccaro, P., van Beek, P., Mohajerin Esfahani, P., y Atasoy, B. (2025). Inverse optimization for routing problems. *Transportation Science*, 59(2), 301–321.
- Zhang, P., Lei, D., Liu, S., y Jiang, H. (2024). Recursive logit-based meta-inverse reinforcement learning for driver-preferred route planning. *Transportation research part E: logistics and transportation review*, 185, 103485.