

UNIVERSIDAD ADOLFO IBAÑEZ

TESIS DE MAGÍSTER

Preferencias en la planificación de rutas

Autor:
Felipe Jesús Meneses
Machuca

Profesores guía:
Javiera Barrera
Luis Aburto
Felipe Lagos

*Tesis realizada acorde a los requerimientos para el grado de
Master of Science in Data Science*

de la

Facultad de Ingeniería y Ciencias

July 5, 2026

UAI

FACULTAD DE
INGENIERÍA Y
CIENCIAS

Contents

1	Introducción	1
1.1	Descripción del Entorno Operacional: SimpliRoute	1
2	Definición del problema u oportunidad	2
2.1	Problema	2
2.2	Análisis de las Causas Basado en la Literatura	2
2.3	Pregunta de Investigación	3
3	Estado del arte	4
3.1	Revisión bibliográfica	4
3.1.1	Aprendizaje en línea de los costos del entorno	5
3.1.2	Preferencias multiobjetivo a nivel de plataforma	5
3.1.3	Modelos de transición y penalización jerárquica	6
3.1.4	Optimización inversa aplicada al ruteo	7
3.1.5	Aprendizaje por refuerzo inverso y aprendizaje profundo basado en preferencias	8
3.1.6	Preferencias individuales y ruteo sensible al contexto	8
3.1.7	Brecha de conocimiento	9
4	Hipótesis y objetivos	11
4.1	Objetivo general	11
4.2	Objetivos específicos	11
	References	12

Chapter 1

Introducción

La última milla constituye el eslabón final y más crítico de la cadena de suministro, encargada de conectar de manera directa el producto de una empresa con el consumidor privado final (Boysen, Fedtke, & Schwerdfeger, 2020). Asimismo, en el escenario contemporáneo, fuertemente impulsado por el auge del comercio electrónico y los servicios de entrega ultra-rápida, este proceso ha adquirido una relevancia estratégica debido a su alta complejidad operacional y sus elevados costos asociados. Así, diversos estudios en el ámbito de la ingeniería de transporte y la logística urbana señalan que la última milla es típicamente considerada la parte más ineficiente de la cadena, llegando a representar cerca del 53% de los costos logísticos totales que enfrentan las organizaciones (Yadav, Dehalwar, & Sharma, 2025).

Por consiguiente, para las empresas del sector retail y de distribución es un imperativo crucial manejar eficientemente sus recursos. De manera que, la optimización nace como una herramienta fundamental para mejorar el manejo de recursos, reducir el consumo y organizar flotas de vehículos en tiempos viables, una tarea que sobrepasa las capacidades de planificación puramente manuales de un ser humano.

1.1 Descripción del Entorno Operacional: SimpliRoute

Ahora bien, la oportunidad de esta investigación se genera y contextualiza en el entorno operativo de SimpliRoute, una plataforma comercial de tecnología para la logística dedicada a ayudar a empresas ofreciendo entregas rápidas, eficientes e inteligentes.

Así, los clientes de SimpliRoute, que incluyen empresas de retail, farmacias y restaurantes, utilizan la plataforma para optimizar sus operaciones de entrega en la última milla. De manera que, la plataforma permite a los usuarios ingresar datos de pedidos, ubicaciones de entrega y restricciones de tiempo, generando rutas optimizadas para los conductores.

Sin embargo, se ha realizado un análisis para verificar el seguimiento de las rutas generadas por SimpliRoute. Donde, se ha notado que sus conductores ignoran las recomendaciones y deciden tomar su propia ruta por razones que no se han identificado, notandose una brecha entre la ruta óptima generada por el algoritmo y la ruta ejecutada en el mundo real.

En consecuencia, este fenómeno de no adherencia a la ruta óptima representa un desafío crítico para la eficiencia operativa de SimpliRoute, ya que impacta directamente en el uso de recursos de los clientes e incluso en los costos logísticos y en la satisfacción del cliente.

Chapter 2

Definición del problema u oportunidad

2.1 Problema

El problema central de esta investigación radica en la severa degradación de la adherencia a la secuencia de clientes planificada por la heurística de SimpliRoute. Así, en el contexto de la última milla, el software modela la operación como un Problema de Ruteo de Vehículos (VRP), donde el objetivo principal es determinar una permutación ordenada de paradas para cada vehículo, minimizando una función de costo basada en distancias y tiempos teóricos de viaje. Sin embargo, los datos empíricos de la plataforma revelan una desconexión crítica con la realidad. Ya que, la tasa de adherencia de los conductores a la secuencia exacta de clientes propuesta por SimpliRoute alcanza apenas un 14.19% (Rubio Carrasco, 2025). Asimismo, esto significa que en el 85.81% de los casos, los operadores alteran deliberadamente el orden de visita de los nodos o clientes a visitar. De manera que, este fenómeno representa un desajuste estructural entre el espacio de soluciones del algoritmo y las decisiones secuenciales óptimas del operador humano.

La persistencia de esta baja adherencia impacta negativamente en la eficiencia proyectada por la plataforma, alterando las estimaciones de tiempos de llegada y de los costos logísticos, arriesgando la confiabilidad del servicio de SimpliRoute.

2.2 Análisis de las Causas Basado en la Literatura

La drástica brecha de adherencia observada no responde a una indisciplina arbitraria del operador logístico, sino a un divorcio estructural entre la formulación matemática del optimizador y la realidad operativa en terreno.

En primer lugar, los motores de ruteo tradicionales resuelven el Problema de Ruteo de Vehículos (VRP) mediante una función de costo lineal que minimiza variables geométricas o temporales explícitas, tales como la distancia total o el tiempo teórico de viaje. Sin embargo, la evidencia empírica señala que los conductores expertos operan bajo un esquema multiobjetivo subjetivo y rara vez eligen el camino más corto o rápido de forma aislada.

La literatura identifica que los operadores humanos evalúan de forma latente variables complejas de representarlas directamente en un modelo. Por ejemplo, algunas de las razones es que desvían sus rutas deliberadamente para evitar segmentos

viales con pavimentos en mal estado, zonas con exceso de semáforos o giros complejos a la izquierda en avenidas saturadas (Zattoni Scroccaro, van Beek, Mohajerin Esfahani, & Atasoy, 2025; Cook, Held, & Helsgaun, 2024; Yang, Guo, Ma, & Jensen, 2015; Pan et al., 2025; Ceikute & Jensen, 2013; T.-Y. Chen, Chang, & Tzeng, 2001). Al omitir estos factores en la función de costo del planificador, el espacio de soluciones del algoritmo termina siendo poco práctico y realista para el conductor.

Además, esta desconexión basada en la simplificación del modelo se profundiza críticamente debido a la exclusión del conocimiento asimétrico que posee el conductor frente a la plataforma. A través de la repetición sistemática de sus rutas, los repartidores desarrollan una profunda familiaridad con sus zonas asignadas, acumulando un conocimiento tácito que no es considerado (Merchán et al., 2024; Canoy, Bucarey, Mandi, & Guns, 2023; Ceikute & Jensen, 2013; Özarık, da Costa, & Florio, 2024). Por lo que, este aprendizaje basado en la experiencia les permite anticipar e integrar de forma intuitiva dinámicas locales, variables que el algoritmo ignora de forma nativa.

En consecuencia, al verse enfrentado a una secuencia algorítmica rígida que contradice este entendimiento empírico del entorno, el conductor opta por priorizar su propio criterio heurístico para asegurar la efectividad real de la entrega, consolidando el fenómeno de desviación analizado.

2.3 Pregunta de Investigación

En base a los antecedentes expuestos, la presente investigación busca responder a la siguiente interrogante ¿Cómo se pueden inferir e integrar las preferencias multiobjetivo y el conocimiento tácito de los conductores, a partir de las discrepancias entre rutas planificadas y trazas GPS históricas, para incrementar la adherencia a la secuencia de paradas por visitar, del motor de optimización en la última milla?

Chapter 3

Estado del arte

3.1 Revisión bibliográfica

La discrepancia entre la ruta planificada por un motor de optimización y la ruta efectivamente ejecutada por el conductor no es una anomalía marginal, sino un fenómeno documentado de forma sistemática en la última milla bajo distintos nombres, como implicit preferences (Canoy et al., 2023), tacit knowledge (Merchán et al., 2024) o context-aware preferences (Cook et al., 2024).

Así, una de las evidencias empíricas más tempranas proviene al comparar trazas GPS de conductores locales contra las rutas sugeridas por servicios de navegación comerciales (Ceikute & Jensen, 2013). De manera que, encontraron que las rutas realmente elegidas no son ni las más cortas ni las más rápidas, sino que se ubican sistemáticamente entre ambos extremos, evidenciando la existencia de un criterio de decisión latente que puede ser medido. Asimismo, esto ocurre en el contexto del desafío de datos de Amazon (Merchán et al., 2024), donde fue otro caso documentado de desviación, evidenciando el problema. En este caso, otro grupo de investigadores cuantificaron que las rutas ejecutadas por conductores reales son en promedio un 12,9 % más largas en tiempo de viaje que la solución óptima teórica (Cook et al., 2024).

Por eso, es necesario preguntarse si efectivamente este tiempo extra que se determino fue debido a un criterio de decisión latente y no por conducción ineficiente.

Por lo tanto, así como se ha evidenciado en otros contextos, la magnitud del fenómeno en SimpliRoute (85,81 % de desviación) sugiere que, lejos de ser una anomalía marginal, el motor de ruteo está resolviendo sistemáticamente un problema distinto al que el conductor enfrenta en terreno.

Como mencionamos previamente, podemos entender que esta desconexión tiene dos raíces. Por un lado, la simplificación de la función de costo, que omite variables complejas que el conductor evalúa de forma latente. Por otro lado, el conocimiento tácito que el repartidor desarrolla a través de la experiencia, que le permite anticipar e integrar de forma intuitiva dinámicas locales que el algoritmo ignora de forma nativa. Así, un intento de formalizar explícitamente estos criterios se encuentra en T.-Y. Chen et al. (2001), quienes, mediante un modelo de asignación de pesos sobre nueve criterios de elección de ruta. En este, mostraron que el tiempo de viaje y las condiciones de tráfico dominan en promedio, pero que el peso de la familiaridad y del hábito del conductor crece cuando la ruta sugerida se aleja de la ruta habitual.

También, la literatura científica contemporánea en logística de última milla ha transitado desde modelos puramente prescriptivos hacia marcos adaptativos basados en

datos que buscan capturar la incertidumbre del entorno urbano y el conocimiento tácito humano a partir de un historial de decisiones pasadas. Ahora bien, para resolver este problema en el contexto de SimpliRoute se requiere satisfacer simultáneamente tres condiciones. Primero, heterogeneidad individual, es decir, aprender el perfil único de cada conductor y no un promedio de la zona. Segundo, escalabilidad, de modo que el enfoque funcione con una gran cantidad de carteras de clientes que cambian todos los días y con trazas GPS dispersas. Y por último, reinyectabilidad operacional, donde el resultado sea directamente consumible por el motor de optimización de SimpliRoute. En torno a estas tres exigencias organizamos la revisión, agrupando la literatura en seis líneas metodológicas.

3.1.1 Aprendizaje en línea de los costos del entorno

Una primera vertiente aborda el problema desde la perspectiva del aprendizaje adaptativo de la red de transporte, en escenarios donde el operador logístico posee información limitada o estocástica sobre los tiempos reales de viaje. Por eso, es posible formalizar el problema del camino más corto modelándolo como un problema de bandidos multibrazo combinatorios (CMAB) bajo un entorno de retroalimentación de tipo semibandit (Lagos, Auad, & Lagos, 2024). En este caso, cada arco de la red vial actúa como un brazo cuyo tiempo de viaje real solo se revela después de haber sido recorrido, y la exploración y explotación se decide mediante el algoritmo de Thompson sampling. Donde, en el caso de implementación, se logro validar al aplicar sobre la red vial de Beijing, el método converge a la solución experta tras pocas iteraciones.

De manera que, esta línea por sí sola es complementaria y no competidora respecto de nuestro problema, ya que aprende los tiempos de viaje objetivos de la red y no las preferencias subjetivas del conductor. Sin embargo, y tambien es mencionado como un desafío, su relevancia radica en poder lograr soluciones cercanas a los conductores, reflejando de cierta manera el criterio latente.

Por eso, incluir el contexto dentro de la metodología es un desafío relevante a este caso. Así, esto se logro incluir en el problema de recomendación, donde se agrego información del contexto, como la hora del día o día de la semana (Li, Chu, Langford, & Schapire, 2010). Así, esta distinción resulta relevante para nuestra investigación, ya que el contexto es justamente uno de los factores que debe separarse de la preferencia personal del conductor.

3.1.2 Preferencias multiobjetivo a nivel de plataforma

Una segunda línea de investigación se enfoca en el aprendizaje de preferencias a nivel macro, es decir, del conjunto completo de decisiones de una plataforma logística en lugar de a nivel de un conductor individual (Nourmohammadi, Hu, Rey, & Saberi, 2025). Así, se introduce un enfoque de optimización guiado por datos para inferir implícitamente las ponderaciones de las funciones objetivo en un Problema de Ruteo Vehicular Capacitado con Ventanas de Tiempo Multiobjetivo (MO-CVRPTW).

Por lo tanto, tras evaluar estadísticamente un conjunto de escenarios históricos, demostraron que las preferencias de los tomadores de decisiones se concentran en tres objetivos principales, la minimización de la distancia total de viaje, la minimización del tamaño de la flota utilizada y el balance de la carga de trabajo. Posteriormente, utilizan el algoritmo de Random Forest (RF) para predecir las funciones objetivo a

partir de las características intrínsecas de las instancias de entrega, eliminando la necesidad de recompilar el motor de optimización en cada exploración de pesos.

Sin embargo, una premisa fundamental de este enfoque es asumir homogeneidad en las preferencias de la flota, ya que el modelo no busca parametrizar el comportamiento aislado de cada conductor, sino capturar la visión unificada del tomador de decisiones. De manera que, podría ser quizás considerable actualizar esta metodología en el sentido de incluir la información por conductor, ya que esta es precisamente la limitación que motiva el primer pilar de nuestra brecha.

3.1.3 Modelos de transición y penalización jerárquica

Asimismo, una línea más consolidada en última milla reemplaza o complementa la matriz de costos del solver por una estructura estimada a partir de las rutas históricas (Canoy et al., 2023). En este caso, se propone un modelo de transición markoviano entre paradas, donde cuanto más frecuentemente un planificador ha en-cadenado dos paradas, mayor es la probabilidad de transición aprendida. De manera que, esta matriz se integra directamente con la infraestructura de optimización existente, combinando el criterio objetivo de distancia con el criterio subjetivo de preferencia, sin necesidad de reformular matemáticamente el VRP subyacente, una propiedad atractiva desde la perspectiva de la reinyectabilidad. Pero, su limitación es que captura la ocurrencia histórica entre arcos, pero no la causa subyacente de cada preferencia.

Sobre esta base se despliegan varias extensiones. Ghosh, Kuiper, Mahes, and Maragno (2023) proponen una descomposición jerárquica que aprende de forma global y optimiza de forma local. Donde, en el nivel global resuelven un problema, tipo traveling salesman problem (TSP), sobre zonas con una matriz de costo que pondera transiciones históricas y distancias, y en el nivel local resuelven un TSP por distancia dentro de cada zona. De manera que, encuentran que la información histórica es decisiva para elegir la zona de inicio, pero que puede descartarse hacia el final de la ruta, momento en el cual la única consideración relevante es el retorno a la estación.

Asimismo, en otro caso se reemplaza el conteo markoviano por una red neuronal que estima las probabilidades de transición incorporando características contextuales, como el día de la semana o la información de parada, y observan que usar las probabilidades de Markov como característica de entrada de la red, en lugar de reemplazarlas, entrega el mejor resultado (Mandi, Canoy, Bucarey, & Guns, 2021).

También, se logra combinar la estimación de probabilidades por zona con predicción estructurada de salida, para aprender automáticamente los pesos que balancean distancia, preferencia y penalización, resolviendo el problema en dos etapas, primero sobre zonas y luego sobre paradas, donde el orden de zonas se penaliza en la función objetivo en lugar de imponerse como restricción dura (Canoy et al., 2024).

En paralelo, la familia de búsqueda local restringida penaliza las secuencias que se alejan de los patrones de zonificación observados históricamente y realizados previamente a la realización de la ruta. Por un lado, el algoritmo LKH-AMZ presentado obtuvo el primer lugar del desafío de Amazon (Cook et al., 2024), alcanzando un score de 0.0248, y demostró una alta eficiencia computacional. Por otro lado, se extiende esta idea con una heurística de inserción guiada por datos (Rashidi, Nourinejad, & Roorda, 2025). Entrenan un modelo basado en energía para predecir la probabilidad de que una ruta sea de alta calidad, usando factores finos como la agudeza

de los giros, la distancia de retroceso y el momento de visita a cada barrio, y generan múltiples tours candidatos, eligiendo el de mayor calidad predicha. Así, reportan un 22,4 % más de soluciones de alta calidad que el ganador del desafío, a costa de un 20,6 % más de tiempo de viaje mediano, exhibiendo de forma explícita el compromiso entre practicidad y eficiencia teórica que cualquier propuesta en esta línea debe discutir.

El rasgo común de toda esta familia es que aprende una estructura de preferencia agregada por zona o por flota, no diferenciada por conductor, y que su calidad depende de una zonificación geográfica previamente definida. Esta zonificación está ausente en el contexto de SimpliRoute, donde las bodegas de los clientes y los manifestos de carga no cuentan con una estructura de zonas equivalente a la de Amazon, lo que impide la transferencia directa del enfoque.

3.1.4 Optimización inversa aplicada al ruteo

Cuando un conductor experto elige una ruta, implícitamente está resolviendo un problema de optimización cuya función objetivo no está siendo modelada matemáticamente. La Optimización Inversa (IO) invierte esta lógica, es decir, en lugar de resolver un problema de optimización dado un objetivo conocido, infiere el objetivo a partir de las soluciones observadas (Ahuja & Orlin, 2001). Donde, el trabajo fundacional en este dominio proponen, a partir de la operación real de una empresa de comercio electrónico china, una formulación de IO que perturba mínimamente la matriz de costos para que las rutas históricas resulten óptimas (L. Chen, Chen, & Langevin, 2021). Y, ante la intratabilidad de la formulación exacta a gran escala, desarrollan dos algoritmos de aprendizaje en línea, uno de ellos basado en actualización multiplicativa de pesos con garantías de convergencia demostrables.

Luego, esta metodología fue posteriormente formalizada y adaptada al VRP (Zattoni Scroccaro et al., 2025), en el que proponen una función hipótesis, una función de pérdida y un algoritmo de optimización estocástico de primer orden específicos para ruteo. El marco define el concepto de TSP restringido y aprende los pesos de arco mediante un ajuste por subgradiente que compara iterativamente la ruta experta con la ruta óptima bajo los pesos actuales. Luego, en su validación sobre el desafío de última milla de Amazon, alcanzaron el segundo lugar entre los 48 equipos finalistas con un puntaje de 0.0302. Resulta ilustrativo que su error de predicción de secuencia de zona sea cercano al 32 % en promedio y que, aun así, el puntaje sea bajo, porque las zonas mal predichas tienden a ser geográficamente cercanas a las correctas.

Ambos trabajos comparten dos limitaciones relevantes frente al contexto de SimpliRoute. En primer lugar, la implementación principal depende de la existencia de una zonificación geográfica preestablecida. En segundo lugar, y más importante, la IO aprende un único vector de parámetros para el conjunto de todas las rutas analizadas, representando un promedio de la flota más que el perfil individual de cada conductor.

Asimismo, una alternativa conceptual a la IO merece mención, ya que, en una investigación se propone prescindir de la estimación de los pesos latentes y predecir directamente la solución combinatoria mediante modelos Transformer entrenados sobre soluciones pasadas, respetando las restricciones duras a través de un módulo de razonamiento de restricciones (Navarro, van Hoes, & Singh, 2026). Aunque su validación se realiza sobre problemas de mochila, emparejamiento y programación de tareas, y no sobre el VRP, el enfoque plantea el compromiso entre desempeño

e interpretabilidad. Ahora bien, la IO entrega pesos interpretables y reinyectables, mientras que la predicción directa opera como una caja negra. Esta distinción es relevante para justificar por qué, dado el requisito de reinyectabilidad, un marco basado en pesos resulta preferible a uno de predicción directa de secuencia.

3.1.5 Aprendizaje por refuerzo inverso y aprendizaje profundo basado en preferencias

El Aprendizaje por Refuerzo Inverso (IRL) parte de una premisa intuitiva. Donde, si se observa el comportamiento de un agente que toma decisiones de forma experta, es posible inferir la función de recompensa que dicho agente está maximizando, aunque esa función nunca haya sido formulada explícitamente (Ng, Russell, et al., 2000). Así, se desarrolla un marco de meta-IRL basado en el modelo logit recursivo para mejorar la precisión y la eficiencia del cálculo de las frecuencias esperadas de visita de estado, abordando dos desafíos clásicos del IRL, la dependencia de aproximaciones numéricas de dichas frecuencias y la dispersión de las trazas GPS (Zhang, Lei, Liu, & Jiang, 2024). Además, en su conjunto de datos de Chengdu, más del 60 % de las solicitudes usan menos del 7 % de los enlaces de la red como destino. También, se propone un marco de aprendizaje profundo basado en preferencias para la estimación de rutas históricas, aprendiendo una representación de la preferencia del conductor a partir de las trazas (Pan et al., 2025).

Estos enfoques aprovechan trazas GPS, el mismo tipo de dato disponible en SimpliRoute, pero presentan dos limitaciones para nuestro contexto. En primer lugar, la representación aprendida de la preferencia no está formulada como una corrección directamente aplicable a la función de costo de un solver VRP existente, sino como una política o una función de recompensa que requeriría rediseñar el sistema de ruteo, lo que incumple el requisito de reinyectabilidad. En segundo lugar, tienden a atribuir a la preferencia personal patrones que pueden deberse al efecto estructural de la asignación de zona.

3.1.6 Preferencias individuales y ruteo sensible al contexto

Una línea reciente aborda de frente la heterogeneidad individual. Así, se argumenta explícitamente que los métodos previos asumen homogeneidad de la flota e introducen ruido al buscar patrones colectivos (Pegado-Bardayo, Lorenzo-Espejo, Muñuzuri, & Onieva, 2024). Por lo que, proponen un marco predictivo que identifica el perfil de ruteo que mejor se ajusta a cada courier y a su área de trabajo, mediante un agrupamiento dinámico de servicios, con número variable de clusters, y la selección automática de la heurística de ruteo por conductor. Además, proponen una métrica de similitud, el Índice de Desorden, más sensible al orden y a la separación de las paradas que las métricas previas.

En base a lo anterior, es hasta donde alcanza esta revisión, el trabajo que más directamente aborda uno de los tres pilares de nuestra brecha. Sus limitaciones frente a SimpliRoute son, no obstante, informativas. Primero, opera sobre secuencias de paradas y clusters, no sobre trazas GPS de alta frecuencia. Segundo, al usar un agrupamiento geográfico, no separa explícitamente el efecto de la zona del efecto personal. Y tercero, su salida es una heurística de ruteo completa asignada por conductor, no un vector de pesos reinyectable en un solver VRP genérico.

La comunidad de bases de datos espaciales ha desarrollado, además, un aparato metodológico maduro para separar el efecto del contexto del efecto personal (Yang et

al., 2015). Donde, se identifican preferencias de conducción individuales que varían según el contexto, por ejemplo la hora del día, modelando los costos dinámicos como variables aleatorias, identificando los contextos de cada conductor mediante el agrupamiento de sus ratios de eficiencia y aprendiendo un vector de preferencia por contexto con ayuda de rutas personalizadas.

Ahora bien, en otra investigación se generaliza esta idea con un tensor de preferencia contextual, definido sobre origen, destino y contexto, que captura preferencias por conductor, zona y tiempo, e incorporan un mecanismo de transferencia de preferencias entre contextos similares para lidiar con la dispersión de las trayectorias, que es exactamente el problema de escalabilidad que enfrenta SimpliRoute cuando un conductor no tiene suficiente historial (Guo, Yang, Hu, Jensen, & Chen, 2020). Finalmente, en otra metodología se propone aprender no un vector puntual, sino que la distribución completa de preferencias condicionada al contexto, mediante inferencia amortizada que retropropaga a través de un problema de optimización entera, lo que permite generalizar a contextos nunca observados (Hudson, Charlin, & Frejinger, 2026).

Estas tres referencias resuelven, en un dominio distinto, el ruteo urbano punto a punto y no el VRP de última milla con zonificación ausente, la separación entre contexto y preferencia personal que constituye el segundo pilar de nuestra brecha. Su aparato es transferible, pero ninguna satisface simultáneamente el requisito de reinyectabilidad en un solver VRP genérico bajo datos de manifiestos sin zonas predefinidas.

3.1.7 Brecha de conocimiento

La revisión revela que las tres condiciones que impone el contexto de SimpliRoute han sido abordadas, pero nunca de forma conjunta.

La primera condición es la heterogeneidad individual. Contrariamente a lo que sugeriría una lectura superficial, no es cierto que la literatura ignore por completo al conductor individual, ya que (Pegado-Bardayo et al., 2024) modela perfiles por courier, y la línea de Yang et al. (2015) y Guo et al. (2020) aprende preferencias personalizadas. La brecha no es, por tanto, la ausencia de modelamiento individual, sino que ningún trabajo lo realiza a partir de la discrepancia entre rutas planificadas y trazas GPS de alta frecuencia en un contexto de VRP de última milla. Los enfoques individuales existentes usan secuencias de paradas o clusters, como en el caso de Pegado-Bardayo et al. (2024), o bien trayectorias urbanas punto a punto sin un plan de referencia, como en Yang et al. (2015) y Guo et al. (2020).

La segunda condición es la separación entre el efecto estructural y el efecto personal. Los enfoques agregados, tanto la IO (L. Chen et al., 2021) (Zattoni Scroccaro et al., 2025), como los modelos de transición por zona (Canoy et al., 2023), (Ghosh et al., 2023), o el enfoque multiobjetivo (Nourmohammadi et al., 2025), no distinguen si un patrón se debe a la asignación de zona o a la preferencia del conductor, lo que puede llevar a atribuir patrones geográficos de la zona a preferencias personales del conductor, o viceversa. Pero, donde sí realiza esta separación, los tensores contextuales (Guo et al., 2020) y los contextos por agrupamiento (Yang et al., 2015), proviene de un dominio distinto y no ha sido adaptada al VRP de última milla.

La tercera condición es la reinyectabilidad operacional. Los enfoques de IRL y de aprendizaje profundo basado en preferencias (Zhang et al., 2024; Pan et al., 2025)

aprenden una representación de la preferencia del conductor que no está formulada como una corrección directamente aplicable a la función de costo de un solver VRP existente. En el contexto operativo de SimpliRoute, el resultado metodológico debe ser consumible por el motor de optimización, ya sea como un vector de pesos ajustado en la función de costo o como una restricción blanda aprendida, sin requerir el rediseño completo del sistema de ruteo. Los enfoques que sí cumplen esta condición, como el modelo markoviano de [Canoy et al. \(2023\)](#) y la optimización inversa, de [L. Chen et al. \(2021\)](#) y [Zattoni Scroccaro et al. \(2025\)](#), fallan en la primera y en la segunda.

En síntesis, existe una brecha metodológica no cubierta en la intersección de estas tres condiciones, un marco capaz de inferir preferencias latentes a nivel individual por conductor, a partir de la discrepancia entre rutas planificadas y trazas GPS históricas, distinguiendo el efecto estructural de la asignación de zona del efecto personal, y cuyo resultado sea directamente reinyectable en un motor de optimización VRP. Esta investigación se posiciona en esa intersección, aprovechando además la disponibilidad, infrecuente en la literatura, de trazas GPS de alta frecuencia con contrapartes de rutas planificadas, un tipo de dato señalado repetidamente como la principal barrera para avanzar en esta línea ([Merchán et al., 2024](#); [Cook et al., 2024](#)).

Chapter 4

Hipótesis y objetivos

Si la función de costo del motor de optimización de SimpliRoute se ajusta con un vector de preferencias inferido de forma individual para cada conductor, a partir de la discrepancia entre las rutas planificadas y las trazas GPS históricas, entonces la adherencia a la secuencia de paradas planificada aumenta respecto de la planificación actual, cuya tasa de referencia es de un 14,19%.

4.1 Objetivo general

Desarrollar un marco metodológico que infiera las preferencias individuales de los conductores de SimpliRoute, a partir de la discrepancia entre las rutas planificadas y las trazas GPS históricas, que distinga el efecto estructural de la asignación de zona del efecto personal, y que integre dichas preferencias en el motor de optimización de ruteo con el fin de incrementar la adherencia a la secuencia de paradas planificada.

4.2 Objetivos específicos

1. Caracterizar y cuantificar la discrepancia entre las rutas planificadas por SimpliRoute y las trazas GPS ejecutadas por los conductores, estableciendo la línea base de adherencia y las métricas de evaluación.
2. Formular un modelo que infiera un perfil de preferencias a nivel individual para cada conductor a partir de dicha discrepancia.
3. Incorporar al modelo un mecanismo que separe el efecto estructural de la zona del efecto personal del conductor.
4. Integrar las preferencias inferidas en el motor de optimización, ya sea como una reponderación de la función de costo o como una restricción blanda aprendida, sin requerir el rediseño del sistema de ruteo.
5. Evaluar el incremento de adherencia del enfoque propuesto respecto de la planificación actual y respecto de un modelo de preferencias agregadas, utilizando las métricas definidas en el primer objetivo.

References

- Ahuja, R. K., & Orlin, J. B. (2001). Inverse optimization. *Operations research*, 49(5), 771–783.
- Boysen, N., Fedtke, S., & Schwerdfeger, S. (2020). Last-mile delivery concepts: a survey from an operational research perspective. *Or Spectrum*, 43(1), 1–58.
- Canoy, R., Bucarey, V., Mandi, J., & Guns, T. (2023). Learn and route: learning implicit preferences for vehicle routing. *Constraints*, 28(3), 363–396.
- Canoy, R., Bucarey, V., Mandi, J., Mulamba, M., Molenbruch, Y., & Guns, T. (2024). Probability estimation and structured output prediction for learning preferences in last mile delivery. *Computers & Industrial Engineering*, 189, 109932.
- Ceikute, V., & Jensen, C. S. (2013). Routing service quality – local driver behavior versus routing services. In *2013 IEEE 14th international conference on mobile data management* (Vol. 1, p. 97–106). doi: 10.1109/MDM.2013.20
- Chen, L., Chen, Y., & Langevin, A. (2021). An inverse optimization approach for a capacitated vehicle routing problem. *European Journal of Operational Research*, 295(3), 1087–1098.
- Chen, T.-Y., Chang, H.-L., & Tzeng, G.-H. (2001). Using a weight-assessing model to identify route choice criteria and information effects. *Transportation Research Part A: Policy and Practice*, 35(3), 197–224.
- Cook, W., Held, S., & Helsgaun, K. (2024). Constrained local search for last-mile routing. *Transportation Science*, 58(1), 12–26.
- Ghosh, M., Kuiper, A., Mahes, R., & Maragno, D. (2023). Learn global and optimize local: A data-driven methodology for last-mile routing. *Computers & Operations Research*, 159, 106312.
- Guo, C., Yang, B., Hu, J., Jensen, C. S., & Chen, L. (2020). Context-aware, preference-based vehicle routing. *The VLDB Journal*, 29(5), 1149–1170.
- Hudson, B., Charlin, L., & Frejinger, E. (2026). Contextual preference distribution learning. In *International conference on the integration of constraint programming, artificial intelligence, and operations research* (pp. 243–261).
- Lagos, T., Auad, R., & Lagos, F. (2024). The online shortest path problem: Learning travel times using a multiarmed bandit framework. *Transportation Science*, 1–32. (Articles in Advance) doi: 10.1287/trsc.2023.0196
- Li, L., Chu, W., Langford, J., & Schapire, R. E. (2010). A contextual-bandit approach to personalized news article recommendation. In *Proceedings of the 19th international conference on world wide web* (pp. 661–670).
- Mandi, J., Canoy, R., Bucarey, V., & Guns, T. (2021). Data driven vrp: A neural network model to learn hidden preferences for vrp. *arXiv preprint arXiv:2108.04578*.
- Merchán, D., Arora, J., Pachon, J., Konduri, K., Winkenbach, M., Parks, S., & Noszek, J. (2024). 2021 amazon last mile routing research challenge: Data set. *Transportation Science*, 58(1), 8–11.
- Navarro, M., van Hoeve, W.-J., & Singh, K. (2026). Inverse optimization without inverse optimization: Direct solution prediction with transformer models. *arXiv preprint arXiv:2602.05306*.
- Ng, A. Y., Russell, S., et al. (2000). Algorithms for inverse reinforcement learning. In *ICML* (Vol. 1, p. 2).
- Nourmohammadi, Z., Hu, B., Rey, D., & Saberi, M. (2025). A data-driven preference learning approach for multi-objective vehicle routing problems in last-mile delivery. *Transportation Research Part C*, 174, 105101. doi: 10.1016/j.trc.2025.105101

- Özarık, S. S., da Costa, P., & Florio, A. M. (2024). Machine learning for data-driven last-mile delivery optimization. *Transportation Science*, 58(1), 27–44.
- Pan, B., Wu, Y., Cao, Z., Hou, Y., Zou, G., & Zhang, Q. (2025, August). Preference-based deep reinforcement learning for historical route estimation. In *Proceedings of the thirty-fourth international joint conference on artificial intelligence (ijcai 2025)*. Montreal, Canada: International Joint Conferences on Artificial Intelligence Organization. doi: 10.24963/ijcai.2025/955
- Pegado-Bardayo, A., Lorenzo-Espejo, A., Muñuzuri, J., & Onieva, L. (2024). A predictive framework for last-mile delivery routes considering couriers' behavior heterogeneity. *Computers & Industrial Engineering*, 198, 110665.
- Rashidi, H., Nourinejad, M., & Roorda, M. (2025). Generating practical last-mile delivery routes using a data-informed insertion heuristic. *Transportation Research Part C: Emerging Technologies*, 179, 105278.
- Rubio Carrasco, T. (2025). *Mejora de adherencia a planificación de ruteo usando machine learning basado en preferencias pasadas* (Tesis de magíster). Universidad Adolfo Ibáñez, Santiago, Chile.
- Yadav, K., Dehalwar, K., & Sharma, S. N. (2025). Assessing the factors affecting first and last mile accessibility in transit-oriented development: A literature review. *GeoJournal*, 90(6), 298.
- Yang, B., Guo, C., Ma, Y., & Jensen, C. S. (2015). Toward personalized, context-aware routing. *The VLDB Journal*, 24(2), 297–318.
- Zattoni Scroccaro, P., van Beek, P., Mohajerin Esfahani, P., & Atasoy, B. (2025). Inverse optimization for routing problems. *Transportation Science*, 59(2), 301–321.
- Zhang, P., Lei, D., Liu, S., & Jiang, H. (2024). Recursive logit-based meta-inverse reinforcement learning for driver-preferred route planning. *Transportation research part E: logistics and transportation review*, 185, 103485.